

Universidade São Judas Tadeu
ENGENHARIA DE SOFTWARE

Gabriel Dias de Moraes Ferreira
Gustavo de Cássio Gomes Perez
Heloisy Aparecida Fernandes Pereira
Ryan Felipe Matos Romano

NortED:

Dando um norte acadêmico para quem está perdido na rotina de estudos, utilizando um comitê de algoritmos de aprendizado de máquina.

São Paulo

Fevereiro, 2026

Sumário

1	Introdução	3
2	Descrição da Base de Dados.....	4
3	Definição do Problema (Target)	5
4	Pré-processamento.....	6
4.1	Prevenção de Vazamento de Dados e Seleção de Atributos	6
4.2	Codificação de Variáveis Categóricas	7
4.3	Normalização e Ajuste de Escala.....	7
4.4	Divisão da Base em Treino e Teste.....	8
5	Modelagem	9
5.1	Árvore de Decisão	9
5.2	K-Vizinhos Mais Próximos	9
5.3	Naive Bayes.....	10
6	Construção do comitê	11
7	Resultados e Metricas	12
7.1	KNN	12
7.2	Naive Bayes.....	12
7.3	Árvore de Decisão	12
8	Conclusão	13

1 INTRODUÇÃO

O desempenho acadêmico dos estudantes é influenciado por uma rede complexa de fatores que transcendem o ambiente formal da sala de aula. Tradicionalmente, as análises educacionais concentram-se de forma estrita no histórico de notas prévias, negligenciando rotinas cotidianas que impactam diretamente a capacidade cognitiva e o foco dos discentes. No cenário contemporâneo, elementos como a qualidade do sono, o tempo dedicado ao uso de redes sociais e a constância nos hábitos de estudo emergem como variáveis críticas para o sucesso ou fracasso escolar.

Diante dessa realidade, o presente trabalho busca explorar como os comportamentos diários e as condições sociofamiliares interagem na determinação dos resultados em exames. Nós decidimos focar a nossa narrativa na vertente dos hábitos e do comportamento, visando compreender em que medida o estilo de vida do estudante atua como um preditor de sua classificação acadêmica final. A relevância desta abordagem reside na possibilidade de fornecer insights para que instituições de ensino compreendam a rotina de seus alunos, permitindo o desenho de estratégias pedagógicas e de conscientização que integrem o bem-estar pessoal ao rendimento escolar.

Para atingir esse objetivo, nós aplicamos conceitos de aprendizado de máquina supervisionado por meio da modelagem e da construção de um comitê de classificadores. Esta metodologia permite avaliar múltiplos algoritmos preditivos operando em conjunto, mitigando vieses individuais e aumentando a robustez da inferência estatística sobre as categorias de notas dos estudantes.

2 DESCRIÇÃO DA BASE DE DADOS

A base de dados selecionada para o desenvolvimento deste projeto intitula-se Student Exam Performance Dataset, sendo composta por 10.000 registros amostrais de estudantes e contendo uma mistura rica de atributos numéricos, categóricos e ordinais. Cada linha da base representa o perfil único de um aluno, detalhando seus dados demográficos, histórico familiar, padrões comportamentais e indicadores de engajamento acadêmico.

Após uma análise exploratória inicial da estrutura dos dados, nós catalogamos as seguintes variáveis originais presentes no arquivo:

Identificadores e Dados Demográficos: student_id (código de identificação do aluno), gender (gênero) e age (idade do estudante).

Contexto Socioeconômico e Familiar: parental_education (nível de escolaridade dos pais), family_income (nível de renda familiar) e internet_access (disponibilidade de acesso à internet em casa).

Rotina e Hábitos Comportamentais: study_hours_per_day (horas diárias dedicadas ao estudo), sleep_hours (horas de sono por noite), social_media_hours (horas diárias gastas em redes sociais) e study_environment (percepção sobre a qualidade do ambiente de estudos, categorizado entre silencioso ou moderado).

Engajamento e Atividades Acadêmicas: attendance_rate (taxa de frequência às aulas), assignment_completion_rate (taxa de entrega de tarefas), participation_score (nota de participação em sala de aula), online_courses_completed (quantidade de cursos online finalizados) e tutoring (indicador de participação em aulas de reforço ou tutoria).

Desempenho Histórico e Avaliações Parciais: previous_gpa (média global acumulada no histórico do aluno), math_score (nota em matemática), reading_score (nota em leitura), writing_score (nota em escrita) e science_score (nota em ciências).

Resultados Finais: pass_fail (situação binária de aprovação ou reprovação) e grade_category (categoria conceitual da nota final atribuída ao estudante).

3 DEFINIÇÃO DO PROBLEMA (TARGET)

O problema central abordado neste projeto consiste em modelar uma tarefa de classificação supervisionada multiclasse. Nós definimos explicitamente que a nossa variável alvo (*target*) será o atributo *grade_category*. Esta variável assume valores discretos e ordinais, mapeando o desempenho final do estudante em cinco categorias conceituais de notas: A, B, C, D e F, em que a categoria A representa o desempenho mais elevado e a categoria F indica a reprovação por insuficiência de nota.

Em termos de inferência estatística e tomada de decisão baseada em dados, o problema afasta-se de uma estimativa puramente contínua para concentrar-se na rotulação de perfis. O desafio reside em treinar os algoritmos para que consigam mapear os padrões multidimensionais gerados pelas variáveis comportamentais e de engajamento, inferindo com precisão em qual faixa de conceitos um estudante se posicionará ao término do período letivo.

As variáveis independentes (*features*) utilizadas para alimentar os modelos classificadores incluirão os dados demográficos, o contexto socioeconômico, todas as métricas de hábitos diários e o engajamento estudantil. Nós decidimos manter também o histórico de desempenho prévio representado pelo *previous_gpa* e pelas notas das disciplinas isoladas, pois compreendemos que o conhecimento base do aluno é um fator de composição relevante. No entanto, o detalhamento das restrições para evitar que o modelo dependa excessivamente destas pontuações em detrimento das variáveis de hábito será formalizado na etapa subsequente de pré-processamento.

4 PRÉ-PROCESSAMENTO

O sucesso da modelagem preditiva depende diretamente da qualidade e da preparação adequada dos dados estruturados. Nesta etapa, nós submetemos a base de dados a um pipeline de transformações matemáticas e estruturais, garantindo que os algoritmos de aprendizado de máquina recebam as informações em um formato padronizado e livre de inconsistências que possam comprometer a generalização dos modelos.

4.1 Prevenção de Vazamento de Dados e Seleção de Atributos

A primeira intervenção realizada na base de dados consistiu na eliminação de variáveis que guardavam uma relação matemática direta e redundante com o resultado final. Nós decidimos excluir os atributos *final_exam_score* e *pass_fail* antes do treinamento dos classificadores. Esta decisão fundamenta-se no conceito de vazamento de dados, dado que a categoria da nota, definida pela variável *grade_category*, é gerada diretamente a partir da pontuação do exame final. Se mantivéssemos tais atributos, os algoritmos criariam regras triviais e obteriam métricas artificialmente perfeitas, anulando a capacidade do modelo de aprender o impacto real das variáveis comportamentais.

Adicionalmente, nós removemos a coluna *student_id*, uma vez que se trata de um identificador sequencial aleatório sem qualquer valor preditivo. Por outro lado, nós preservamos o histórico de desempenho representado por *previous_gpa* e pelas notas das disciplinas isoladas, pois eles contextualizam o ponto de partida acadêmico de cada estudante.

4.2 Codificação de Variáveis Categóricas

Os algoritmos de aprendizado de máquina selecionados exigem matrizes numéricas para a execução de suas operações algébricas e probabilísticas. Como a base de dados original apresenta diversas variáveis textuais, nós realizamos um processo de codificação.

Para atributos binários como *gender* e *internet_access*, nós aplicamos o mapeamento direto para valores zero e um. Para atributos ordinais ou categóricos com múltiplos níveis, como *parental_education*, *family_income* e *study_environment*, nós empregamos a técnica de codificação de rótulos (Label Encoding), convertendo as categorias em uma escala numérica linear que preserva a gradação de níveis de forma simplificada, otimizando o processamento para os classificadores base.

4.3 Normalização e Ajuste de Escala

A base de dados possui variáveis numéricas com intervalos de valores muito distintos, a exemplo da taxa de frequência, que varia em uma escala percentual, e do tempo de sono, medido em poucas horas diárias. Algoritmos baseados em cálculo de distâncias geométricas, como é o caso do método dos K-Vizinhos Mais Próximos, são altamente sensíveis a essas diferenças de magnitude, tendendo a priorizar atributos com valores nominalmente maiores.

Para mitigar esse viés, nós aplicamos a padronização Z-score em todos os atributos numéricos. Este procedimento transforma as variáveis de modo que todas passem a apresentar uma média igual a zero e um desvio padrão igual a um, equalizando a importância de cada característica durante o cálculo das fronteiras de decisão.

4.4 Divisão da Base em Treino e Teste

A etapa final do pré-processamento consistiu na fragmentação da base de dados original em dois conjuntos mutuamente exclusivos. Nós adotamos a divisão clássica de mercado, reservando 80% dos dados para o processo de treinamento e ajuste dos parâmetros dos classificadores e mantendo os 20% restantes isolados para a etapa de teste e avaliação de desempenho.

Nós decidimos aplicar a estratificação com base na variável alvo `grade_category`, garantindo que tanto o conjunto de treino quanto o de teste mantivessem rigorosamente a mesma proporção original de alunos categorizados em cada nota, evitando desbalanços que pudessem distorcer a validação dos modelos.

5 MODELAGEM

Na etapa de modelagem, nós selecionamos três algoritmos preditivos distintos para compor a base do nosso sistema de classificação. A escolha por modelos com naturezas matemáticas e lógicas fundamentalmente diferentes foi intencional. O nosso objetivo primordial foi garantir a diversidade técnica necessária para a posterior construção de um comitê robusto, partindo da premissa de que algoritmos com funcionamentos variados tendem a cometer erros em instâncias diferentes, permitindo uma compensação mútua de falhas.

5.1 Árvore de Decisão

O primeiro algoritmo que nós implementamos foi a Árvore de Decisão. Este método opera por meio da divisão recursiva do espaço de características, criando regras lógicas condicionais a partir dos dados de treinamento. No contexto do nosso projeto educacional, a árvore é capaz de mapear caminhos interpretáveis e muito próximos do raciocínio humano. O algoritmo pode, por exemplo, identificar automaticamente que se um aluno dorme menos de cinco horas por noite e consome mais de quatro horas em redes sociais, ele possui uma alta propensão a pertencer à categoria de nota D ou F. A principal vantagem deste modelo reside na sua transparência estrutural e na facilidade de explicação das regras geradas para as partes interessadas da instituição de ensino.

5.2 K-Vizinhos Mais Próximos

O segundo classificador implementado foi o método dos K-Vizinhos Mais Próximos, frequentemente abreviado como KNN. Diferente da abordagem puramente lógica da árvore, o KNN baseia-se na geometria e no cálculo de distâncias matemáticas no espaço multidimensional. Na prática, o algoritmo avalia o perfil comportamental e socioeconômico de um estudante e procura os alunos mais similares a ele dentro da base de dados histórica. A

inferência da categoria de nota é dada pela classe majoritária entre essa vizinhança. O uso deste modelo justifica fortemente a etapa prévia de padronização dos dados, pois asseguramos que variáveis com magnitudes diferentes, como a taxa percentual de frequência e as horas diárias de estudo, possuam o mesmo impacto no cálculo de similaridade geométrica.

5.3 Naive Bayes

O terceiro modelo que nós selecionamos foi o Naive Bayes, especificamente na sua formulação Gaussiana para dados contínuos padronizados. Trata-se de um classificador fundamentado no Teorema de Bayes, que calcula a probabilidade estatística de um aluno pertencer a uma determinada faixa de nota dado o seu conjunto específico de hábitos e características. Embora o modelo assuma a hipótese simplificadora de que as variáveis independentes não possuem correlação entre si, ele é reconhecido na literatura científica por apresentar um desempenho surpreendentemente veloz e eficaz em problemas de classificação multidimensionais. O Naive Bayes oferece uma perspectiva estritamente probabilística que complementa perfeitamente as abordagens baseadas em regras e em distâncias dos modelos anteriores.

6 CONSTRUÇÃO DO COMITÊ

Na etapa culminante do nosso fluxo de processamento, nós procedemos à criação do comitê de classificadores, consolidando a estratégia conhecida na literatura como Ensemble Learning. A premissa fundamental desta abordagem estabelece que a combinação das previsões de múltiplos modelos independentes resulta em uma decisão final mais generalista, robusta e imune a ruídos do que a avaliação de qualquer algoritmo isolado.

Para a integração dos três especialistas previamente treinados, nós optamos pela implementação da técnica de Voto Majoritário (Hard Voting). Este mecanismo opera de maneira direta e transparente. Para cada estudante presente no conjunto de teste, a Árvore de Decisão, o algoritmo K-Vizinhos Mais Próximos e o Naive Bayes emitem os seus diagnósticos individuais sobre qual será a categoria da nota final. O comitê recolhe essas três previsões e atribui ao aluno a classificação que recebeu a maioria dos votos, de forma estritamente democrática.

Nós escolhemos esta estratégia de agregação devido à sua alta interpretabilidade e sinergia com a nossa seleção de modelos. Como os nossos algoritmos base possuem naturezas matemáticas diametralmente opostas, operando por regras lógicas, cálculo de distâncias e probabilidade estatística, eles tendem a apresentar pontos cegos em situações diferentes. O comitê atua como um mecanismo de correção mútua, garantindo que o erro de um classificador específico seja mitigado e superado pelo acerto consensual dos demais membros do grupo.

Cabe ressaltar a mecânica de resolução de impasses inerente à implementação computacional do comitê. Em cenários de classificação multiclasse, é estatisticamente possível a ocorrência de empates absolutos, situações nas quais cada um dos três modelos prediz uma categoria de nota completamente distinta para o mesmo estudante. Para lidar com essas instâncias, nós mantivemos o critério de desempate padrão da biblioteca de desenvolvimento, que soluciona o conflito selecionando a classe com a maior precedência na ordem alfabética entre as opções votadas. Com esta abordagem, nós asseguramos que o sistema preditivo preserve o seu caráter determinístico, garantindo a emissão de um diagnóstico final mesmo diante de divergências integrais entre os especialistas.

7 RESULTADOS E METRICAS

Nesta etapa, nós avaliamos o desempenho dos algoritmos utilizando os 20% dos dados separados previamente para o conjunto de teste. A validação do sistema preditivo baseou-se nas métricas de Acurácia Global, Precisão, Recall e F1-Score, utilizando a média ponderada para compensar o volume de alunos em cada faixa de nota, além da análise visual das matrizes de confusão geradas para cada classificador.

7.1 KNN

Após uma análise de otimização que identificou $K=19$ como o número ideal de vizinhos, o algoritmo baseou-se em distâncias padronizadas para alcançar uma acurácia de **87,30%** e F1-Score de **86,64%**.

7.2 Naive Bayes

Este classificador destacou-se como o melhor modelo individual do projeto, atingindo **90,50%** de acurácia, com Precisão de **91,09%** e F1-Score de **90,68%**. Sua abordagem probabilística lidou de forma altamente eficaz com as múltiplas dimensões do comportamento dos alunos.

7.3 Árvore de Decisão

O modelo obteve uma acurácia de **86,45%**, com F1-Score de **86,45%**. Embora ofereça excelente interpretabilidade de suas regras lógicas, apresentou uma leve penalização na generalização frente aos demais.

8 CONCLUSÃO

O presente trabalho demonstrou com sucesso a viabilidade técnica de prever o desempenho acadêmico de estudantes utilizando predominantemente seus padrões de comportamento, engajamento e contexto socioeconômico. Atingir uma precisão em torno de **90%** através da análise de variáveis cotidianas, como horas diárias de sono, tempo dedicado às redes sociais e taxa de frequência, corrobora a nossa tese inicial de que o sucesso escolar transcende o histórico de notas e é fortemente ditado pelo estilo de vida do aluno.

A construção do Comitê de IAs unindo as lógicas recursivas da Árvore de Decisão, a semelhança espacial do KNN e o cálculo de probabilidades do Naive Bayes, provou ser uma arquitetura sólida e confiável para a rotulação multiclasse do desempenho educacional.

Do ponto de vista prático e institucional, o impacto deste projeto é altamente promissor. Como o sistema conseguiu identificar com assertividade os padrões comportamentais que levam à reprovação (Categoria F), ele pode ser implementado por instituições de ensino como uma ferramenta de diagnóstico e alerta precoce, podendo ajudar alunos em estados mais críticos. Essa tecnologia permitirá aos educadores desenhar intervenções pedagógicas direcionadas, ajustes no ambiente de estudo e apoio tutorial customizado de forma proativa, operando antes da ocorrência dos exames finais e garantindo o desenvolvimento sustentável e o bem-estar do corpo discente, vale ressaltar que esse projeto não descarta a necessidade humana para a análise já que existem outras variáveis que podem influenciar na nota do aluno.